TEAM PRESENTATION

SSAFY 15기| AI Challenge

재활용품 이미지 VQA 최종 전략 발표

Qwen2.5-VL 7B, QLoRA, full-data 학습, logprob 추론, 선택지 셔플 TTA로 구성한 최종 제출 전략을 공유합니다.

출발! 드림팀

대전 6반

이강륜 · 윤병현 · 박동규 · 김영호

Scale-up | Full-data | Logprob | TTA

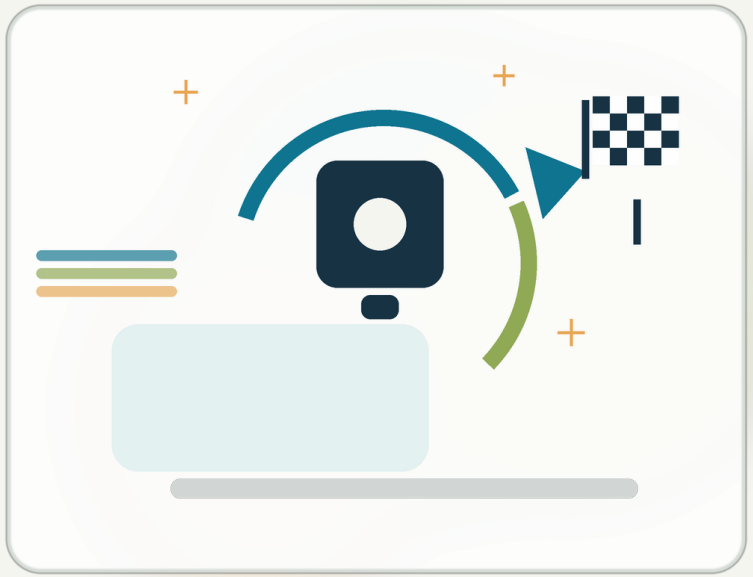

작은 시각 단서를 더 잘 읽고, 선택지 편향을 더 적게 믿는 방향으로 전략을 다듬었습니다.

01

문제 정의와 승부 조건

정답률 게임이기 때문에 모델 자체보다도 데이터 활용 방식과 추론 안정성이 직접 점수로 이어졌습니다.

대회 입력 / 출력

문제

- 입력: 재활용품 이미지 + 한국어 4지선다 질문
- 출력: a / b / c / d 중 하나의 답
- 평가지표: Accuracy

데이터 규모

train	5,073
dev	4,413
test	5,074

무엇이 어려웠나

세부 시각 단서
라벨, 재질, 광택, 찌그러짐처럼 작은 단서가 정답을 가름

한국어 객관식
질문 해석 + 보기 비교 + 문자 하나만 출력해야 함

선택지 편향
VLM이 특정 위치의 보기를 선호하면 accuracy가 바로 깎임

결론: 학습 성능 + 추론 안정화 + 데이터 확대를 동시에 잡는 전략이 필요했습니다.

02

최종 전략 한 장 요약

성능 향상은 한 번의 묘수가 아니라 네 개의 작은 결정이 누적된 결과였습니다.

Model scale-up

- Qwen2.5-VL 3B → 7B
- 384px → 672px
- H100 80GB로 학습 여유 확보

Fine-tuning tuning

- LoRA r=8 → 64
- LR 1e-4 → 1e-5
- 3 epoch + cosine scheduler

Data expansion

- train + dev 전체 학습
- dev는 5인 다수결로 gold 생성
- 9,486개까지 학습 데이터 확대

Inference control

- logprob 직접 추출
- 선택지 셔플 TTA
- 앙상블은 자동선택 후 기각

핵심 메시지 큰 모델 하나가 답이 아니라 **데이터 확대 + 안정적인 선택지 비교 + 편향 제거**를 함께 묶었을 때 public score가 올라갔습니다.

03

3B 베이스라인에서 7B 튜닝 전략으로

하이퍼파라미터 변화는 각각 이유가 있었고, 모두 작은 시각 단서를 더 잘 잡기 위한 방향이었습니다.

변경 요약	Baseline	Final / A
모델	3B	7B
해상도	384px	672px
LoRA rank	8	64
LR	1e-4	1e-5
Epoch	1	3
Scheduler	linear	cosine
GPU	RTX 5060 Ti	H100 80GB

왜 이 조합이 먹혔나

세 가지 핵심 가설

- 재활용 분류는 작은 시각 단서에 민감하므로 해상도와 모델 크기가 직접 성능으로 이어진다.
- LoRA rank를 키운 만큼 LR를 낮춰야 과도한 업데이트 없이 안정적으로 적응한다.
- 1 epoch으로는 부족하고, cosine으로 후반부를 눌러줘야 미세한 경계가 정리된다.

결과적으로 모델 capacity를 키우되, 학습은 더 조심스럽게 움직이는 방향으로 설계했습니다.

04

데이터 전략: FULL_DATA_MODE로 학습량 확대

dev를 버리지 않고 다수결 gold로 흡수하면서, 학습 데이터 부족 문제를 가장 직접적으로 해결했습니다.

데이터 볼륨 변화

train only

5,073

train + dev majority vote

9,486 +87% 데이터 확대

dev를 어떻게 썼나

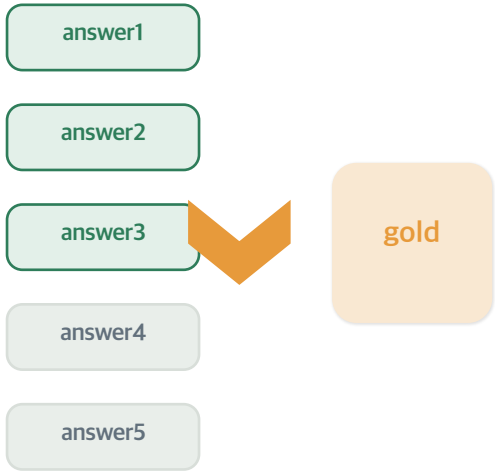

운영 방식

학습 세팅

- train + dev 전체를 학습에 사용
- 검증은 100샘플만 모니터링 용도로 유지
- patience=999로 early stopping 사실상 비활성화
- 3 epoch를 고정으로 끝까지 학습

데이터가 부족한 상황에서는 정교한 regularization보다 usable label을 더 확보하는 쪽이 효과적이었습니다.

05

프롬프트는 짧지만 도메인 힌트는 분명하게

정답 형식은 극단적으로 단순하게 유지하되, 재질/개수 구분에 필요한 관찰 포인트만 system prompt에 실었습니다.

System prompt 핵심

1. 개수 세기: 겹치거나 일부만 보여도 포함

2. 재질 판별: 플라스틱 / 유리 / 금속 / 종이 / 비닐 / 스티로폼 구분

3. 금속 vs 플라스틱: 광택, 반사, 찌그러짐 패턴으로 구분

4. 출력 형식: a, b, c, d 중 하나의 소문자 한 글자

왜 이렇게 설계했나

프롬프트 원칙

- 도메인 힌트는 넣되, 답안 형식은 한 글자로 강하게 제한
- 객관식 보기는 user prompt에서 고정 포맷으로 전달
- 금속/플라스틱처럼 자주 헷갈리는 경계 사례를 직접 언급
- 복잡한 chain-of-thought보다 관찰 기준을 주는 쪽이 대회 환경에 더 실용적

요약: 프롬프트는 모델을 '똑똑하게' 만들기보다, 시선을 어디에 둘지 정렬하는 장치로 사용했습니다.

06

generate 대신 logprob 직접 비교

문자 하나를 뽑는 문제에서는 생성 문장을 후처리하는 것보다 a/b/c/d의 확률을 바로 비교하는 쪽이 훨씬 깨끗했습니다.

기존 방식

model.generate() → 문자열 파싱 → a/b/c/d 추출

문제점

- 불필요한 토큰이 섞이면 후처리 규칙이 복잡해짐
- 선택지별 확신도를 직접 비교하기 어려움
- 앙상블이나 TTA에서 점수를 평균내기 까다로움

최종 방식

forward pass로 a / b / c / d 각 토큰의 logprob를 직접 추출

a	b	c	d
-1.91	-0.73	-2.24	-1.35

장점: 확률 비교, 앙상블 평균, TTA 역매핑이 모두 같은 score space에서 처리됩니다.

07

TTA: 선택지 순서를 섞어 position bias 제거

정답 그 자체보다 보기의 위치를 덜 믿게 만드는 것이 목적이었습니다.

4개 permutation에서 같은 질문을 다시 묻고, logprob를 원래 위치로 역매핑한 뒤 평균합니다.

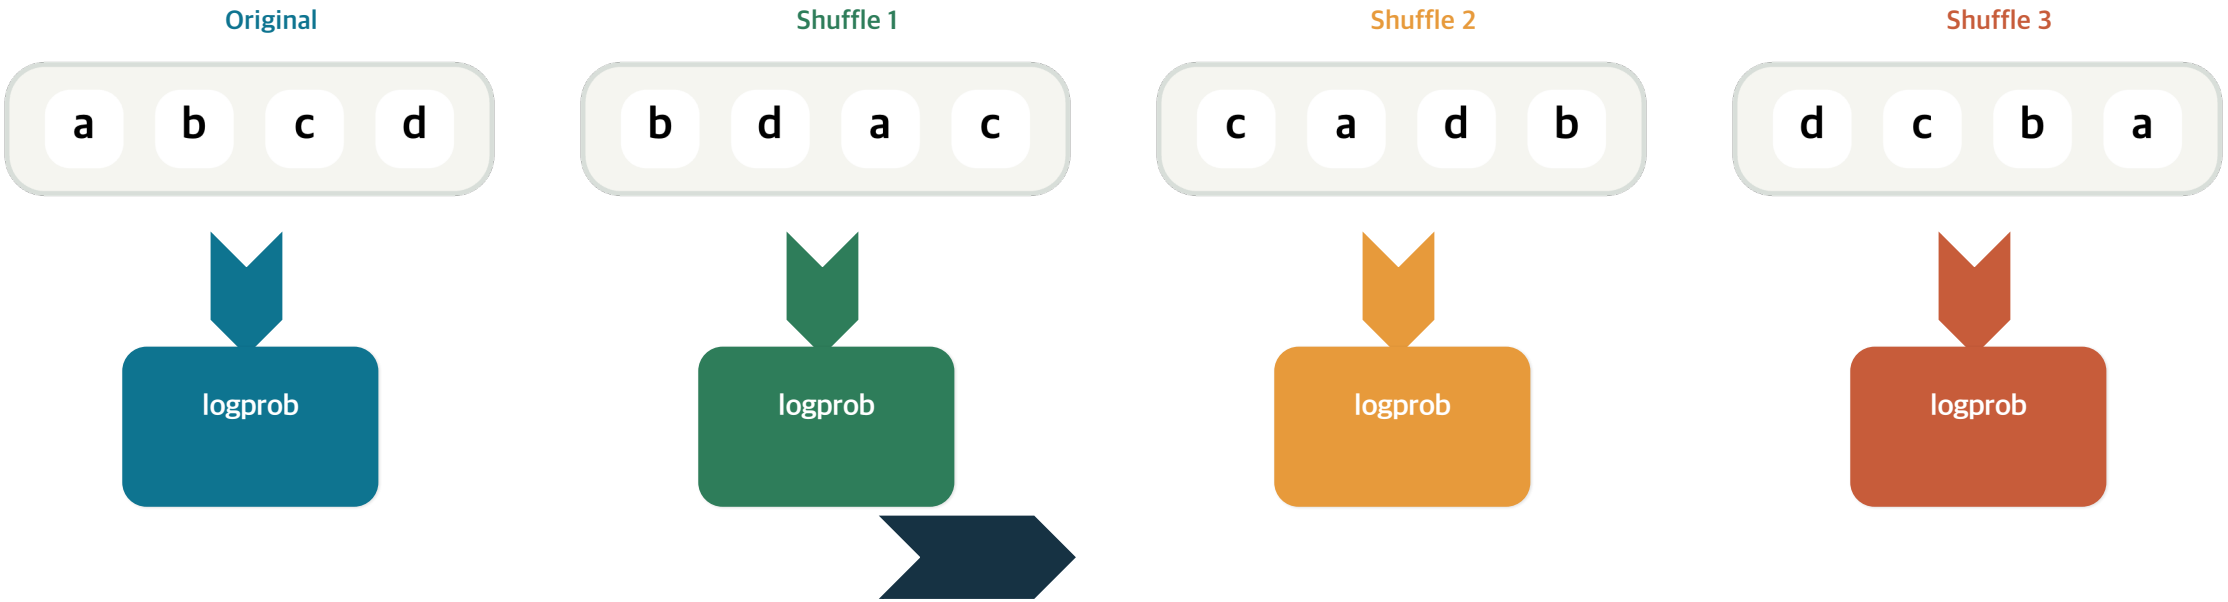

효과: 모델이 특정 위치의 선택지를 선호하더라도 평균 과정에서 편향이 상쇄됩니다.

역매핑 후 평균 → 최종 argmax

실전 결과: tuned Model A에서 TTA가 가장 높은 public score 0.91761을 기록했습니다.

실험 결과: TTA가 최종 우승 전략

성능 차이는 크지 않지만, 작은 차이를 만드는 요인이 무엇인지가 분명하게 드러났습니다.

Public score 비교

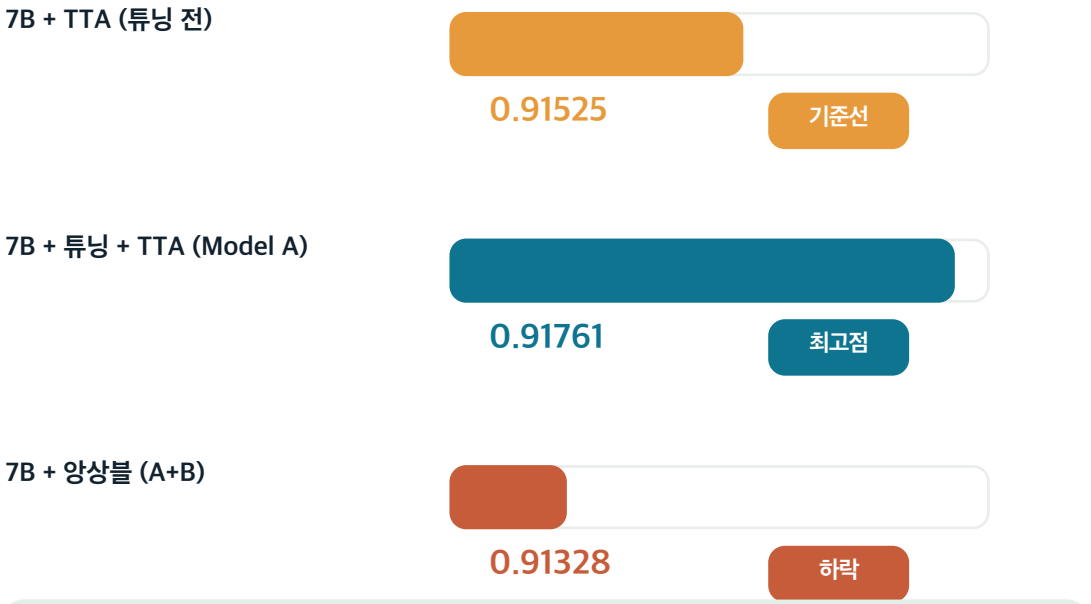

+0.00236 improvement

해석

관찰 포인트

- 하이퍼파라미터 튜닝과 FULL_DATA_MODE가 기준선 대비 실질적인 상승을 만들었다.
- Model B를 따로 만든 것 자체는 나쁘지 않았지만, 앙상블이 항상 정답은 아니었다.
- 작은 score 차이에서도 운영 전략이 최종 제출물을 바꾸는 결정적 요소가 됐다.

대회형 문제에서는 '복잡한 방법'보다 '안정적으로 반복 가능한 방법'이 더 강했습니다.

09

왜 앙상블이 실패했는가, 그리고 다음 액션

잘못된 자동선택은 validation 설계와 모델 다양성 부족이 겹쳤을 때 쉽게 발생합니다.

앙상블 하락 원인

validation overfit

FULL_DATA_MODE에서 validation이 학습 데이터 일부 100샘플뿐이라, 앙상블 우위가 과적합된 숫자였음

lack of diversity

A/B 모두 같은 아키텍처와 거의 같은 데이터로 학습되어 에러 패턴이 충분히 달라지지 않았음

selection rule mismatch

val 기준 자동선택 규칙은 있었지만, public leaderboard 일반화 성능까지는 보장하지 못했음

이번 대회에서 남은 교훈

- 앙상블은 다양성이 있을 때만 유효하다.
- full-data 학습에서는 validation 신뢰도 설계가 더 중요하다.
- position bias 제거처럼 직접적인 추론 보정이 의외로 강하다.

다음에 해볼 것

- 다른 VLM과의 heterogeneous ensemble
- cross-validation + OCR / prompt ensemble

Final takeaway: 최고점은 큰 모델 하나보다 학습량 확대와 추론 통제를 묶은 운영 전략에서 나왔습니다.